

Fisher打分法

尽管最大似然方法应用实例可能会给出不同的估计式，但通常无法给出最大似然估计量的显式公式。在这种情况下，我们需要使用数值近似方法。

对于给定的观测值 x ，似然函数 $\theta \mapsto L(\theta; x)$ 是参数 θ 的一个“正常”函数，而我们需要找到使该函数达到最大值的 θ 值。我们可以使用牛顿-拉夫森（Newton-Raphson）方法，或者该方法的变体，在统计学中被称为 Fisher 打分法（Fisher's Scoring）。现在我们简要描述这些数值方法。

在大多数情况下，所需的值 $\hat{\theta}$ 是对数似然函数相对于 θ 的导数的驻点。因此，我们讨论找到函数 $\theta \mapsto \dot{\Lambda}(\theta; x)$ 的零点 $\hat{\theta}$ ，其中 $\dot{\Lambda}$ 是对数似然函数的偏导数向量 $\theta \mapsto \Lambda(\theta; x) = \log L(\theta; x)$ 。牛顿-拉夫森方法的思想是从 $\hat{\theta}$ 的“合理”初始估计值 $\tilde{\theta}_0$ 出发，并用线性近似替换函数 $\dot{\Lambda}$ ，这里要注意的是初始值的选择非常重要，否则将会造成比较严重的误差：

$$\dot{\Lambda}(\theta; x) \approx \dot{\Lambda}(\tilde{\theta}_0; x) + \ddot{\Lambda}(\tilde{\theta}_0; x) (\theta - \tilde{\theta}_0)$$

这里， $\ddot{\Lambda}(\theta; x)$ 是对数似然函数相对于参数的二阶导数矩阵。我们不再寻找 $\dot{\Lambda}(\theta; x) = 0$ 的解，而是转向求解方程 $\dot{\Lambda}(\tilde{\theta}_0; x) + \ddot{\Lambda}(\tilde{\theta}_0; x) (\theta - \tilde{\theta}_0) = 0$ 。该方程的零点为

$$\tilde{\theta}_1 = \tilde{\theta}_0 - \ddot{\Lambda}(\tilde{\theta}_0; x)^{-1} \dot{\Lambda}(\tilde{\theta}_0; x)$$

由于线性近似并不精确， $\tilde{\theta}_1$ 通常不是期望的零点 $\hat{\theta}$ 。然而，我们预计 $\tilde{\theta}_1$ 比初始值 $\tilde{\theta}_0$ 更接近 $\hat{\theta}$ 。然后将 $\tilde{\theta}_1$ 作为初始值，计算第三个值，依此类推。这就形成了一个近似序列 $\tilde{\theta}_0, \tilde{\theta}_1, \tilde{\theta}_2, \dots$ ，在某些条件下，该序列收敛于零点 $\hat{\theta}$ 。如果初始值 $\tilde{\theta}_0$ 足够接近目标值 $\hat{\theta}$ 并且函数 $\dot{\Lambda}$ 足够光滑，收敛是可以保证的，但在实践中我们当然无法保证这一点。

对算法的各种不同修改可以使收敛更可靠。然而，如果这个对数似然函数有多个局部极大值和/或极小值，则需要小心，首先得一种坏情况就是收敛到 $\dot{\Lambda}$ 的另一个零点（对应于局部极大值或极小值），此外，序列 $\tilde{\theta}_0, \tilde{\theta}_1, \tilde{\theta}_2, \dots$ 还可能发散。

在之后章节中，我们将看到，对数似然函数在最大似然估计量 $\hat{\theta}$ 处的二阶导数 $\ddot{\Lambda}(\hat{\theta}; x)$ 具有特殊意义。该二阶导数称为观测信息，与 Fisher 信息近似相等。在牛顿-拉夫森算法中，有时使用另一种矩阵代替二阶导数。比如这里如果如果使用 Fisher 信息，则该算法称为 Fisher 打分法。值得一提的是，当利用 Fisher 信息解析计算时，这种方法特别有趣。